

Laboratorium SJ.

Lab. 2 - Elementy statystyki

Zadania do wykonania w środowisku Matlab

1) Założenie: prawdopodobieństwo, że wylosowana do próbki jednostka jest niezgodna wynosi p . Napisać funkcję obliczającą prawdopodobieństwo, że w próbce o licznosci N wystąpi co najmniej K elementów niezgodnych oraz wykreślić zależność wartości tej funkcji od K ($K=1..N$) dla zadanych wartości p i N (np. $p=0.05$, $N=50$). Wejściami funkcji są zmienne p , N i K ($0 < p < 1$, $K \leq N$). Wzór pomocniczy: prawdopodobieństwo wystąpienia dokładnie K elementów niezgodnych wynosi:

$$P(K) = \binom{N}{K} \cdot p^K \cdot (1-p)^{N-K}$$

2) X jest zmienną losową o rozkładzie normalnym ze średnią μ i odchyleniem standardowym σ . Napisać funkcję wyznaczającą prawdopodobieństwo P zdarzenia, że $\left| \frac{X - \mu}{\sigma} \right| > k$, gdzie k jest zadaną liczbą.

Napisać funkcję, która dla zadanego prawdopodobieństwa P zdarzenia, że $\left| \frac{X - \mu}{\sigma} \right| > k$ oblicza wartość k .

3) Sprawdzenie normalności rozkładu danych (lub zgodności danych z dowolnym typem rozkładu).

Dla dowolnej ustalonej liczby p , $p \in (0,1)$, kwantylem rzędu p rozkładu prawdopodobieństwa o dystrybuancie $F(x)$ nazywamy taką wartość x_p , że $F(x_p) = p$. Jeżeli dokonamy ustawienia losowych wyników pomiarów $X_1 \dots X_N$ w porządku niemalejącym: $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(N)}$ oraz dokonamy standaryzacji zmiennej losowej X , tak aby wartość średnia wynosiła 0, a odchylenie standardowe 1, to wartość oczekiwana statystyki pozycyjnej $X_{(r)}$ może być przybliżona przez kwantyl $K_{(r-0.5)/N}$ rzędu $(r-0.5)/N$ standardowej zmiennej losowej Z o rozkładzie normalnym $N(0,1)$. Zatem jeśli przebieg wykresu składa się z punktów $\{X_{(r)}, K_{(r-0.5)/N}\}$, to jeżeli próbka pochodzi z rozkładu normalnego, przebieg wykresu powinien być zbliżony do linii prostej. Odstępstwo od linii prostej sugeruje, że zmierzona próbka nie pochodzi z rozkładu normalnego. Podobnie testuje się zgodność rozkładu próbki dla innych typów rozkładów.

Napisać funkcję, która dla zadanej próbki losowej o licznosci N wykona wykresy sprawdzające, czy próbka pochodzi z rozkładu normalnego. Funkcję przetestować dla próbek symulowanych z rozkładu normalnego (`randn`) i równomiernego (`rand`) dla różnych licznosci próbek N (np. $N = 100, 10^4, 10^6$).

4) Estymatory odchylenia standardowego

Na podstawie N -próbek K -elementowych można wyznaczyć następujące estymatory nieobciążone odchylenia standardowego:

$\sigma_1 = a(K) \cdot \bar{s}$, gdzie \bar{s} - średnie odchylenie standardowe wyznaczone z N -odchyłeń standardowych pojedynczych próbek, $a(K)$ – współczynnik zależny od licznosci próbek K .

$\sigma_2 = b(K) \cdot \bar{R}$, gdzie \bar{R} jest rozstępem średnim z N próbek K -elementowych, $b(K)$ – współczynnik zależny od licznosci próbek K .

$\sigma_3 = c(K) \cdot med(s)$, gdzie $med(s)$ jest medianą odchyłeń standardowych z N -próbek K -elementowych, $c(K)$ – współczynnik zależny od licznosci próbek K .

Współczynniki $a(K)$, $b(K)$ i $c(K)$ zawarto w poniższej tabeli:

Liczność próbki K	$a(K)$	$b(K)$	$c(K)$
2	1.253	0.8865	1.1829
3	1.1284	0.5907	1.0646
4	1.0854	0.4857	1.0374
5	1.0638	0.4300	1.0260
6	1.0510	0.3946	1.0201
7	1.0423	0.3698	1.0161
8	1.0363	0.3512	1.0136
9	1.0317	0.3367	1.0116
10	1.0281	0.3249	1.0103
15	1.0180	0.2880	1.0063
20	1.0133	0.2677	1.0046

Napisać funkcję wyznaczającą opisane estymatory odchylenia standardowego dla N -próbek K -elementowych dla $K=2..20$. Wartości współczynników dla brakujących w tabeli licznosci próbek wyznaczyć z zastosowaniem interpolacji.

Dla wybranej licznosci próbki K przetestować symulacyjnie, który spośród trzech estymatorów odchylenia standardowego jest najefektywniejszy i wyrazić efektywność pozostałych dwóch względem niego.

5) Wygenerować wektor liczb losowych z rozkładu normalnego o wartości oczekiwanej μ i odchyleniu standardowym σ (wartości parametrów rozkładu przyjąć arbitralnie). Na jego podstawie wykreślić histogram (doświadczalną funkcję gęstości) oraz dystrybuantę. Do wykonania wykresów użyć funkcji `bar()` i wyników odpowiednio wywołanej funkcji `hist()` lub `histcounts()` – które wyznaczają położenia binów i liczby zliczeń w binach. Znormalizować histogram (suma powierzchni słupków histogramu znormalizowanego powinna być równa jedności) i przedstawić go na wykresie razem z teoretyczną funkcją gęstości (`normpdf`). Na podstawie znormalizowanego histogramu wykreślić dystrybuantę. Porównać na drugim wykresie dystrybuantę doświadczalną z dystrybuantą teoretyczną (`normcdf`). Histogramy i dystrybuanty doświadczalne wykreślić dla kilku różnych długości wektora liczb losowych.